

# RAPPORT TP DEEP LEARNING - INSA Lyon 5IF

Paul-Emmanuel SOTIR <[paul-emmanuel.sotir@insa-lyon.fr](mailto:paul-emmanuel.sotir@insa-lyon.fr)> ; <[paul-emmanuel@outlook.com](mailto:paul-emmanuel@outlook.com)>

- Course link <https://perso.liris.cnrs.fr/christian.wolf/teaching/deeplearning/tp.html>
- Github repository: <https://github.com/PaulEmmanuelSotir/BallDetectionAndForecasting>

## Introduction

L'objectif de ce projet est d'acquies des connaissances autour de l'aspect empirique du deep learning. Ce projet est l'occasion de mieux maitriser le framework pytorch dans un cas d'utilisation simple mais relativement complet.

Ce TP se divise en deux taches: implémenter un modèle à base de réseaux neuronaux pour la detection de balles colorées dans des images et un modèle de prédiction de la position future de balles.

Le dataset utilisé dans ce projet est un sous-ensemble du dataset synthétique crée pour les experimentations décrites dans le papier suivant : [Fabien Baradel, Natalia Neverova, Julien Mille, Greg Mori, Christian Wolf. COPHY: Counterfactual Learning of Physical Dynamics. pre-print arXiv:1909.12000, 2019.](#)

Une des particularités de ce dataset que l'on a observés lors de l'exploration des données est que toutes les images (100x100) ne comprennent que trois balles et chaque balles d'une même image ont une couleur différente parmi les 9 couleurs possibles.

J'ai également pu observer une certaine redondance d'information de par la représentation des données utilisée: les bounding boxes des balles indiquent la couleur, de par leur position dans le tenseur, alors que les informations de couleurs sont déjà présentes dans le vecteur de couleurs. Un des points important de ce TP est que le dataset est pensé pour éviter certaines difficultés communes à la detection d'objet: avec un nombre constant de balles à detecter, les modèles à implémenter sont bien plus simples (pas d'approches récurantes (RCNN) ou similaires aux modèles de detection tels que SSD ou Yolo). De même, il est peut-être possible que la redondance des informations est la conséquence d'une démarche visant à rendre l'entrainement plus simple sur les bounding boxes en donnant une sémantique claire et simple de l'emplacement et l'ordre des boundings boxes à inferer (ordre/emplacement donné par la couleur). Ainsi, il n'y a pas besoin de penser une 'loss' ou un post-traitement spécifique qui rendrais le modèle invariant à l'ordre des bounding boxes (autrement, le modèle aurait plus de mal à converger puisque même si il infère des bounding boxes parfaites, si elles sont données dans le 'mauvais ordre', alors l'erreur sera importante).

Pour une meilleure reproductibilité des résultats, nous avons fixé les seeds aléatoires de `numpy.random`, `python.random`, de `torch.manual_seed` ainsi que `torch.cuda.manual_seed_all`.

Les données fournies pour ce TP sont divisées en deux sous datasets associés aux deux tâches/parties de ce TP :

### Tache 1 : detection de balles

Le but de cette première tâche est dans un premier temps d'implémenter un modèle la couleur des balles d'un image en entrée. Puis dans un second temps, d'ajouter au modèle entraîné, l'inférence des coordonnées des bounding boxes donnant la position des balles dans l'image en entrée.

## Tache 2 : prédiction de la position future de balles

La seconde partie de ce TP vise à implémenter un modèle pouvant prédire la position future de 3 balles à partir d'une séquence de 19 observations dans le temps de la position des balles dans les images (prédiction de la 20ème observation des balles). Ce modèle ne prend pas nécessairement d'image en entrée, seulement la séquence passée de positions de balles et le vecteur de couleurs d'images suffisent (on suppose que l'image ne contient pas d'informations supplémentaires sur le mouvement des balles).

Entraîner un modèle sur cette seconde tâche amène le modèle à inférer partiellement et implicitement les propriétés physiques de la balles. En effet le dataset synthétique a été généré en simulant le mouvement de balles avec des propriétés physiques variables (masses, frottements, ect...) et ces paramètres ne sont nullement disponibles au delà de l'observation du comportement de la balle. Ce dataset est pensé pour que le problème posé ne soit pas totalement résolvable (*'ill posed problem'*) puisque les propriétés physiques des balles ne peuvent pas être complètement connues à partir de la séquence seule.

On peut aussi se poser la question, concernant le vecteur de couleurs des balles, de si les propriétés physiques des balles sont elles partiellement corrélées avec leur couleurs respective. Si on prend pour à-priori qu'il n'y a pas de causalité alors on peut ignorer totalement les couleurs pour cette partie du TP.

Nous faisons le choix de prendre le vecteur des couleurs en entrée de notre modèle. A supposer qu'il n'y a pas d'information pertinentes sur les mouvements de balles dans leur couleurs, il faut espérer que le dataset ne présente pas de corrélations sans causalité (nous n'avons pas exploré cet aspect dans l'EDA) et que la régularisation du modèle suffirait à surmonter les légères corrélation.

### Run instructions

Les dépendances du projets sont gérées avec un environnement conda; Il suffit donc d'une distribution conda (e.g. Anconda ou Miniconda) et de créer l'environnement conda pour pouvoir exécuter le code. Les fichiers python `../src/train.py` (entraînement d'un modèle avec les meilleurs hyperparamètres trouvés) et `../src/hp.py` (recherche d'hyperparamètres exécutant de nombreux entraînements sur moins d'epochs) sont les deux points d'entrée principaux. Ces deux programmes doivent avoir pour argument `--model detect` (tâche 1: détection de balles) ou `--model forecast` (tâche 2: prédiction de position de balle future).

Ci dessous les instructions d'installation et des exemples d'exécution d'entraînements et de recherches d'hyperparamètres sur les tâches 1 et 2 :

```
##### Installation #####

git clone git@github.com:PaulEmmanuelSotir/BallDetectionAndForecasting.git
conda env create -f ./environnement.yml
conda activate torch_5if
# Télécharge les datasets (nécessite les packages 'curl' et 'tar' sur une
distribution Linux (ou WSL - Linux subsystem on Windows))
bash ./download_dataset.sh

##### Exemples d'utilisation #####

# Entraîne le modèle de détection de balles (tâche 1) avec les meilleurs
hyperparamètres trouvés
python -O ./src/train.py --model detect
```

```
# Exécute une recherche d'hyperparamètres pour la détection de balles (hyperopt)
python -O ./src/hp.py --model detect | tee ./hp_detect.log
# Entraîne le modèle de prédiction de position de balles (tâche 2) avec les
meilleurs hyperparamètres trouvés
python -O ./src/train.py --model forecast
# Exécute une recherche d'hyperparamètres pour la prédiction de position de la
balles (hyperopt)
python -O ./src/hp.py --model forecast | tee ./hp_forecast.log
```

Exemple d'entraînement du modèle de détection de balles :

```
(pytorch_5if) pes@pes-desktop:~/BallDetectionAndForecasting$ python -O
./src/train.py --model detect
> Initializing and training ball detection model (mini_balls dataset)...
> __debug__ == False - Using 16 workers in each DataLoader...
> MODEL ARCHITECTURE:
BallDetector(
  (_layers): Sequential(
    (0): Sequential(
      (0): Conv2d(3, 4, kernel_size=(3, 3), stride=(1, 1))
      (1): ReLU()
      (2): BatchNorm2d(4, eps=1e-05, momentum=0.07359778246238029, affine=True,
track_running_stats=True)
    )
    (1): Sequential(
      (0): Conv2d(4, 4, kernel_size=(3, 3), stride=(1, 1))
      (1): ReLU()
      (2): BatchNorm2d(4, eps=1e-05, momentum=0.07359778246238029, affine=True,
track_running_stats=True)
    )
    (2): Sequential(
      (0): Conv2d(4, 4, kernel_size=(3, 3), stride=(1, 1))
      (1): ReLU()
      (2): BatchNorm2d(4, eps=1e-05, momentum=0.07359778246238029, affine=True,
track_running_stats=True)
    )
    (3): AvgPool2d(kernel_size=(2, 2), stride=(2, 2), padding=0)
    (4): Sequential(
      (0): Conv2d(4, 16, kernel_size=(5, 5), stride=(1, 1))
      (1): ReLU()
      (2): BatchNorm2d(16, eps=1e-05, momentum=0.07359778246238029, affine=True,
track_running_stats=True)
    )
    (5): Sequential(
      (0): Conv2d(16, 16, kernel_size=(5, 5), stride=(1, 1))
      (1): ReLU()
      (2): BatchNorm2d(16, eps=1e-05, momentum=0.07359778246238029, affine=True,
track_running_stats=True)
    )
    (6): AvgPool2d(kernel_size=(2, 2), stride=(2, 2), padding=0)
    (7): Sequential(
      (0): Conv2d(16, 32, kernel_size=(5, 5), stride=(1, 1), padding=(2, 2))
```

```
> Training on trainset 100%|███████████████████████████████████████████| 1181/1181  
[Elapsed=00:13, Remaining=00:00, Speed=87.46batch/s, batch_size=16, lr=6.537E-04,  
trainLoss=0.1557234]  
  
> Done: TRAIN_LOSS = 0.1540092  
  
> Evaluation on validset 0%|  
| 0/131 [Elapsed=00:00, Remaining=?, Speed=?batch/s, BatchSize=16]> ! Saving  
visualization images of inference on some validset values...  
  
> Evaluation on validset 100%|
```

```

[Elapsed=00:00, Remaining=00:00, Speed=193.57batch/s, BatchSize=16]
> Done: VALID_LOSS = 0.1374522
> Best valid_loss found so far, saving model...
...
...
...

```

Une fois les recherches d'hyperparamètres lancées ou terminées, on peut utiliser les fonction outils `balldetect.torch_utils.extract_from_hp_search_log()` et `balldetect.torch_utils.summarize_hp_search()` pour explorer les résultats d'une recherche d'hyperparamètres sur un notebook jupyter, par exemple (voir le notebook [../notebooks/ball\\_detection\\_hp\\_search\\_results.ipynb](#), les logs bruts situé dans le dossier [../hp\\_search\\_logs/](#), l'annexe à la fin de ce rapport pour les résultats des recherches d'hyperparamètres ou [../src/hp.py](#) pour l'implémentation de la recherche d'hyperparamètres avec le module '**hyperopt**').

## Developement et documentation

### Architecture du projet

Le projet est constitué d'un module Python 'balldetect' contenant :

- L'implémentation (définition, entraînement, évaluation) des deux modèles résolvant les tâches 1 et 2 (`../src/balldetect/ball_detector.py` et `../src/balldetect/seq_prediction.py`)
- Le code pour charger/prétraiter les datasets (`../src/balldetect/datasets.py`)
- `torch_utils.py` contenant diverses fonction réutilisables, notamment pour la définition et entraînement d'un modèle pytorch
- Et également un fichier fournit facilitant la visualisation des images avec ou sans bounding boxes (`../src/balldetect/vis.py`)

Les fichiers `../src/train.py` et `../src/hp.py` sont les points d'entrée pour, respectivement, l'entraînement d'un modèle (detection ou forecasting) avec les meilleurs paramètres trouvés et la recherche d'hyperparamètres (detection ou forecasting) cherchant les meilleurs hyperparamètres 'sampled' dans un espace défini.

Organisation du dossier du projet :

```

- BallDetectionAndForecasting
  - src/                                # Code source du projet
    - balldetect/                        # Module 'balldetect'
      - __init__.py
      - ball_detector.py                # Modèle de detection de balles (tâche 1)
      - datasets.py                    # Objets datasets (fourni), création des
dataloaders et fonction 'retrieve_data'
      - seq_prediction.py              # Modèle de prédiction de position de balles
(tâche 2)
      - torch_utils.py                 # Fonctions définissant du code commun
réutilisable: Couches de convolution ou denses; parralelize; Flatten ; tqdm
personnalisé; ...
      - vis.py                         # Visualization des images avec boundings boxes

```

```
(fourni)
- train.py # Code utilisant le module 'balldetect' pour
entraîner le modèle de détection ou de prédiction de position de balles
- hp.py # Code de recherche d'hyperparamètres
- notebooks/
- ball_detection_hp_search_results.ipynb # Notebook inspectant le résultat
des recherches d'hyperparamètres
- test_fastai.ipynb # Notebook 'brouillon' testant une approche
préliminaire au TP avec fastai (tâche 1.1)
- test_fastai-bbox.ipynb # Notebook 'brouillon' testant une approche
préliminaire au TP avec fastai (tâche 1.2: version avec bounding-boxes)
- datasets/
- mini_balls/
- mini_balls_seq/
- hp_search_logs/ # Dossier des logs d'exécution des recherches
d'hyperparamètres ('../src/hp.py')
- docs/
- rapport.md # Ce rapport au format original (markdown)
- rapport.html
- ball_detection_hp_search_results.html
- figures/ # Dossier d'images/figures contenues dans ce
rapport
- download_dataset.sh # Script de téléchargement des datasets
- environment.yml # Environnement conda, définit les dépendances
- LICENSE
- README.md
- .gitignore
```

### Tests préliminaires avec fastai (voir notebooks 'brouillons' [test\\_fastai.ipynb](#) [test\\_fastai-bbox.ipynb](#))

Dans un premier temps, avant de coder l'approche avec des modèles Pytorch personnalisés. Des premiers tests ont été faits avec fastai pour avoir une idée de la difficulté de la première tâche et ainsi avoir une baseline. L'approche avec fastai, certes très peu didactique ou optimisée en termes de taille de modèle, permet des résultats assez corrects de manière très rapide. Il s'agissait de tester des modèles connus (e.g. variantes de ResNet) préentraînés sur des images ImageNet ou autre. Un rapide fine-tuning sur le dataset de détection de balles permet d'obtenir une détection raisonnable en 3-4 lignes de code.

Une des fonctionnalités également intéressantes de fastai est l'implémentation d'une méthode pour déterminer un meilleur learning rate sans avoir à exécuter une recherche d'hyperparamètres classique (type random-search): le learning rate est déterminé le temps d'une seule époque en changeant le learning rate à chaque batch d'entraînement (voir [callbacks.lr\\_finder de fastai](#)).

Cette approche préliminaire a permis de mieux connaître les avantages et inconvénients d'une utilisation très basique de fastai (en effet, fastai n'empêche pas un contrôle complet sur le modèle entraîné et la procédure d'entraînement). Les résultats obtenus permettent dans la suite de pouvoir mieux interpréter les valeurs des métriques sur ce dataset (donne une baseline raisonnable).

### Petites optimizations du code

- Le(s) GPU disponibles seront utilisés automatiquement si possible:

```
# Device donné en argument de la fonction '.to(DEVICE)' des torch.Tensor
DEVICE = torch.device('cuda') if torch.cuda.is_available() else
torch.device('cpu')
```

- Les dataloaders utilisent plusieurs sous-processus en fonction du nombre de coeurs CPU disponibles sur la machine (paramètre `num_workers` des Dataloader-s) :

```
# Nombre de 'thread' utilisés pour chaque dataloader
_DEFAULT_WORKERS = 0 if __debug__ else min(os.cpu_count() - 1, max(1,
os.cpu_count() // 4) * max(1, torch.cuda.device_count()))
```

- Pour une meilleure optimization des opérations de Pytorch sur GPU, on peut activer l'auto-tuning (basé sur un benchmark) de la librairie CuDNN s'ajoutant à CUDA. CuDNN est une librairie de NVidia (un fichier cpp et une header C++ ajouté au toolkit CUDA) qui offre des optimisations spécifiques aux réseaux de neurones (Convolutions, produits de matrices, calcul du gradient, ...). CuDNN est intégré à Pytorch comme pour CUDA qui est simplement une dépendance installée dans l'environnement Conda. Pytorch permet d'améliorer les performances de CuDNN d'avantage avec les paramètres  `cudnn.benchmark`  et  `cudnn.fastest` . Cependant, activer le benchmarking de CuDNN dans Pytorch peut impacter la reproductibilité des résultats étant donné que ce n'est pas un processus déterministe (même avec  `torch.backends.cudnn.deterministic = True` ). On observe une amélioration de la vitesse d'entraînement entre 30% et 40% pour les modèles Pytorch de detection et de prédiction de position de balles:

```
# Torch CuDNN configuration
torch.backends.cudnn.deterministic = True
cudnn.benchmark = torch.cuda.is_available() # Enable builtin CuDNN auto-tuner,
TODO: benchmarking isn't deterministic, disable this if this is an issue (and
disable parallelization to which isn't deterministic neither)
cudnn.fastest = torch.cuda.is_available() # Disable this if memory issues
```

- Les performances ont aussi été un facteur important dans les choix d'hyperparamètres et d'architecture des modèles (espace de recherche des hyperparametres avec hyperopt). Par exemple, l'architecture du detecteur contient des couches de convolution avec du *average pooling* (remplaçant le 'stride' de 2 dans les dernières variantes du modèle) pour réduire la quantité de paramètres et de features à traiter. Les deux modèles ont un nombre total de couches relativement faibles. Pareillement, le nombre de filtres de convolution, la taille des filtres (3x3 ou, plus haut dans la convolution, 5x5) et la largeur des couches fully-connected ont été choisis, en autre, pour être assez faibles étant donné la simplicité apparante de la tâche de détection et pour permettre un entraînement plus rapide.
- Les entraînements des modèles sont également accélérés en parallélisant les 'training steps' sur plusieurs GPUs automatiquement avec  `model = nn.DataParallel(model)`  (voir la fonction  `parallelize(model: nn.Module) -> nn.Module`  dans  `../src/balldetect/torch_utils.py` ). Les modèles ont été entraîné sur une machine personnelle dotée de deux NVidia 1080 ti; La parallélisation des données avec cette fonction automatique de Pytorch vas donc executer deux entraînements en

parallèle et synchroniser les gradients à chaque étapes de manière synchrone en calculant la moyenne des deux 'training steps' avant de passer à l'entraînement sur les prochains batches.

De par le besoin de synchronisation des gradients, le modèle et/ou les données/batch\_size doivent être assez volumineux pour que cette parallélisation offre une accélération de l'entraînement par rapport à l'utilisation d'un seul GPU.

Par exemple, on observe pour le modèle de detection de balles qu'il faut une **batch\_size** souvent supérieure à 64 pour que les deux 1080 ti soit utilisées au delà de 50% (nvidia-smi). Cependant, trop augmenter la batch\_size peut poser des problèmes, notamment à cause de la taille limitée du dataset et, pour des modèles plus importants, pourrais demander une quantité de mémoire vidéo trop grande.

### **Tache 1: Modèle de detection de balles (voir [../src/balldetect/ball\\_detector.py](#) et les hyperparamètres associés dans [../src/train.py](#))**

Le modèle que nous avons construit pour la détection de balles devait dans un premier temps ne détecter que les couleurs de balles et non leur positions dans l'image (bounding boxes).

Dans un second temps, nous avons modifié le modèle pour inférer également les bounding boxes. Les données issues du dataset ayant une redondance, en autre, au niveau des couleurs de balles (information de couleur présente à la fois dans l'ordre des bounding boxes et dans le vecteur de couleurs), nous avons implémenté deux alternative :

- Une première où le modèle est entraîné directement à inférer les 9 bounding boxes ainsi que le vecteur de couleurs (dont 6 sont à 0 pour une image donnée)
- Une seconde variant où les bounding boxes sont prétraitée pour en enlever les vecteurs nuls : seul 3 bounding boxes sont inférées en plus du vecteur de couleurs (le vecteur de couleurs inféré alors par le modèle définit la position bounding boxes en sortie (voir **BallsCFDetection.\_\_getitem\_\_** et **retrieve\_data** dans [../src/balldetect/datasets.py](#)) : le modèle fait donc en sortie une régression de 3 bounding boxes (3x4 coordonnées) et une *multi-label classsification* pour donner en sortie le vecteur de couleurs (9 valeurs binaires, dont 3 sont à 1 et les autres à 0)

J'ai également testé rapidement une autre alternative où seul les bounding boxes sont inférées et la couleur est déduite de la position des trois vecteurs de coordonnées maximaux; Mais étant donné que la tâche demandée dans le sujet implique que le modèle infère à la fois le vecteur de couleurs et les bounding boxes (d'après ma compréhension du sujet), je n'ai pas exploré cette variante d'avantage.

Un résultat interessant que j'ai pu observer est qu'inférer seulement 3 bounding boxes au lieu de 9 dont 6 nulles n'améliore pas forcément les performances du modèle, voir le contraire. Cette observation peut avoir plusieurs explication :

Comme expliqué à l'introduction, la structure de données pour les bounding boxes dans une matrice de 9 vecteurs de coordonnées est plus simple/claire au niveau de l'ordre/position des vecteurs de coordonnées, alors que l'inférence de 3 bounding boxes, même avec l'ordre initial conservé, a moins de sens.

Il est également possible que ce résultat soit dû à d'autres problèmes dans le modèle qui ont été résolus par la suite, sans avoir réévalué l'interet de cette simplification des bounding boxes.

La loss utilisée pour entrainer le modèle est l'addition de deux termes/métriques :

- Le premier terme de la loss est la métrique BCE (**Binary Cross Entropy**) évaluant la qualité de la classification 'multi-label' sur le vecteur binaire de couleurs. Ce terme est multiplié un hyperparamètre



avant d'être ajouté au deuxième terme de la loss (facteur souvent mis à : `bce_loss_scale=0.1`)

- Le second terme est la métrique MSE (**Mean Squared Error**) minimisant l'erreur au carré moyenne sur la régression des coordonnées des bounding boxes.

Le modèle est composé d'un '*convolution backbone*' suivi d'une ou plusieurs couches denses (*fully connected layer*). L'architecture du modèle contient également des couches `nn.AvgPooling2d` dans le *backbone* de convolutions.

Nous avons implémenté l'architecture de manière relativement générique de manière à pouvoir en définir facilement des variantes dans les hyperparamètres.

Une couche de convolution ou dense (`nn.Conv2d` ou `nn.Linear`) peut-être composée d'une fonction d'activation (hyperparametre `architecture.act_fn`), de *dropout* (si `architecture.dropout_prob != 1.`), de *batch normalization* (si `architecture.batch_norm` définit les paramètres '`eps`' et '`momentum`'). Voir [../src/balldetect/torch\\_utils.py](#) pour plus de détails sur l'implémentation des couches.

Pour ce modèle, nous avons principalement exploré les fonctions d'activation `nn.ReLU` et `nn.LeakyReLU`. Les tailles de filtres de convolutions considérées sont principalement de **3x3**, **5x5** et parfois **7x7** et **1x1** (avec des padding correspondant). Nous avons également exploré l'utilisation de stride à 2 ou 4 avant de remplacer cette pratique par de l'average pooling.

Le Modèle a été entraîné sur le dataset `mini_balls` composé de 20000 images. Le dataset est découpé aléatoirement en un 'trainset' (90% du dataset) et un 'validset' (10% du dataset). Malheureusement, nous n'avons pas eu le temps d'implémenter une cross-validation qui aurait été utile étant donné la petite taille du dataset. En effet, dans cette configuration, le validset est un peu trop petit et il risque d'y avoir des instabilités sur les valeurs des métriques d'évaluation qui pourrait, en outre, fausser la recherche d'hyperparamètres. De plus, nous n'avons pas créé de 'testset' pour une évaluation plus ponctuelle par crainte de perdre d'avantage de données d'entraînement avec un dataset de cette taille. Cependant, il aurait peut-être été pertinent d'en créer un pour mesurer la présence d'overfitting sur le validset dû à la recherche d'hyperparamètres.

La recherche d'hyperparamètre a permis de trouver de bien meilleurs paramètres d'entraînement et choisir la bonne variante d'architecture parmi celles définies dans l'espace d'hyperparamètres. Nous avons pu définir plusieurs espaces d'hyperparamètres relativement restreints à la lumière des résultats obtenus avec des paramètres définis subjectivement.

Ci-dessous, les deux derniers espaces de recherche d'hyperparamètres utilisés avec hyperopt pour la détection de balles dans `../src/hp.py` (algorithme `tpe.suggest` avec 2x100 entraînements de 90 epochs et un `early_stopping` de 12 epochs):

### L'un des premiers espaces de recherche d'hyperparamètres utilisé :

> **NOTE: L'architecture est définie ici (par '`conv2d_params`' et '`fc_params`') de manière différente du code actuel, de par un refactoring rendant plus générique la définition de l'architecture avec les hyperparamètres (legacy hp search space) :**

```
hp_space = {
    'optimizer_params': {'lr': hp.uniform('lr', 5e-6, 1e-4), 'betas': (0.9,
0.999), 'eps': 1e-8,
                        'weight_decay': hp.loguniform('weight_decay',
math.log(1e-7), math.log(1e-3)), 'amsgrad': False},
    'scheduler_params': {'step_size': 40, 'gamma': 0.2}, # LR Steps
    #'scheduler_params': {'max_lr': 1e-2, 'pct_start': 0.3, 'anneal_strategy':
```

```

'cos'}, # One cycle policy
'batch_size': hp.choice('batch_size', [32, 64, 128]),
'architecture': {
    'act_fn': nn.LeakyReLU,
    'dropout_prob': hp.choice('dropout_prob', [1.,
hp.uniform('nonzero_dropout_prob', 0.45, 0.8)]),
    # 'batch_norm': {'eps': 1e-05, 'momentum': 0.1, 'affine': True},
    # Convolutional backbone block hyperparameters
    'conv2d_params': hp.choice('conv2d_params', [
        [{'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1, 'stride':
2},

         {'out_channels': 8, 'kernel_size': (5, 5), 'padding': 2},
         {'out_channels': 8, 'kernel_size': (7, 7), 'padding': 3}],

        [{'out_channels': 2, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1, 'stride':
2},

         {'out_channels': 8, 'kernel_size': (5, 5), 'padding': 2},
         {'out_channels': 8, 'kernel_size': (5, 5), 'padding': 2, 'stride':
2},

         {'out_channels': 16, 'kernel_size': (7, 7), 'padding': 3}],

        [{'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 8, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 8, 'kernel_size': (3, 3), 'padding': 1, 'stride':
2},

         {'out_channels': 16, 'kernel_size': (5, 5), 'padding': 2}],

        [{'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 1, 'stride':
4},

         {'out_channels': 8, 'kernel_size': (3, 3), 'padding': 1},
         {'out_channels': 8, 'kernel_size': (3, 3), 'padding': 1}
    ]),
    # Fully connected head block hyperparameters (a final FC inference layer
    with no dropout nor batchnorm will be added when ball detector model is
    instantiated)
    'fc_params': hp.choice('fc_params', [[{'out_features': 64}],
                                         [{'out_features': 64},
{'out_features': 128}],
                                         []]))
}

```

**Second/dernier espace de recherche d'hyperparamètres (architecture des convolutions fixée):**

```

# Ball detector Conv2d backbone layers (nouvelle façon de définir l'architecture)
conv_backbone = (
    ('conv2d', {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 0}),
    ('conv2d', {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 0}),
    ('conv2d', {'out_channels': 4, 'kernel_size': (3, 3), 'padding': 0}),
    ('avg_pooling', {'kernel_size': (2, 2), 'stride': (2, 2)}),
    ('conv2d', {'out_channels': 16, 'kernel_size': (5, 5), 'padding': 0}),
    ('conv2d', {'out_channels': 16, 'kernel_size': (5, 5), 'padding': 0}),
    ('avg_pooling', {'kernel_size': (2, 2), 'stride': (2, 2)}),
    ('conv2d', {'out_channels': 32, 'kernel_size': (5, 5), 'padding': 2}),
    ('conv2d', {'out_channels': 32, 'kernel_size': (7, 7), 'padding': 3}),
    ('avg_pooling', {'kernel_size': (2, 2), 'stride': (2, 2)}),
    ('conv2d', {'out_channels': 64, 'kernel_size': (5, 5), 'padding': 2}),
    ('flatten', {}))

# Define hyperparameter search space (second hp search space iteration) for ball
detector (task 1)
detect_hp_space = {
    'optimizer_params': {'lr': hp.uniform('lr', 1e-6, 1e-3), 'betas': (0.9,
0.999), 'eps': 1e-8,
                        'weight_decay': hp.loguniform('weight_decay',
math.log(1e-7), math.log(3e-3)), 'amsgrad': False},
    'scheduler_params': {'step_size': 40, 'gamma': .3},
    # 'scheduler_params': {'max_lr': 1e-2, 'pct_start': 0.3, 'anneal_strategy':
'cos'},
    'batch_size': hp.choice('batch_size', [16, 32, 64]),
    'bce_loss_scale': 0.1,
    'early_stopping': 12,
    'epochs': 90,
    'architecture': {
        'act_fn': nn.ReLU,
        'batch_norm': {'eps': 1e-05, 'momentum': hp.uniform('momentum', 0.05,
0.15), 'affine': True},
        'dropout_prob': hp.choice('dropout_prob', [0.,
hp.uniform('nonzero_dropout_prob', 0.1, 0.45)]),
        'layers_param': hp.choice('layers_param', [(*conv_backbone,
('fully_connected', {'out_features': 64})),
                                                    ('fully_connected', {})),
                                                    (*conv_backbone,
('fully_connected', {'out_features': 64})),
                                                    ('fully_connected',
{'out_features': 128})),
                                                    ('fully_connected', {})),
                                                    (*conv_backbone,
('fully_connected', {'out_features': 128})),
                                                    ('fully_connected',
{'out_features': 128})),
                                                    ('fully_connected', {})),
                                                    (*conv_backbone,
('fully_connected', {})))]
    }
}


```

La dernière recherche d'hyperparamètres a donné les paramètres "optimaux" suivants  
(**best\_valid\_loss=0.0031991** après **82** epochs) :

```
{
  DETECTOR_HP = {
    'batch_size': 16,
    'bce_loss_scale': 0.1,
    'early_stopping': 30,
    'epochs': 400,
    'optimizer_params': {'amsgrad': False, 'betas': (0.9, 0.999), 'eps': 1e-08,
    'lr': 6.537177808319479e-4, 'weight_decay': 6.841231983628692e-06},
    'scheduler_params': {'gamma': 0.3, 'step_size': 40},
    'architecture': {
      'act_fn': nn.ReLU,
      'batch_norm': {'affine': True, 'eps': 1e-05, 'momentum':
0.07359778246238029},
      'dropout_prob': 0.0,
      'layers_param': (('conv2d', {'kernel_size': (3, 3), 'out_channels': 4,
'padding': 0}),
                        ('conv2d', {'kernel_size': (3, 3), 'out_channels': 4,
'padding': 0}),
                        ('conv2d', {'kernel_size': (3, 3), 'out_channels': 4,
'padding': 0}),
                        ('avg_pooling', {'kernel_size': (2, 2), 'stride': (2,
2)}),
                        ('conv2d', {'kernel_size': (5, 5), 'out_channels': 16,
'padding': 0}),
                        ('conv2d', {'kernel_size': (5, 5), 'out_channels': 16,
'padding': 0}),
                        ('avg_pooling', {'kernel_size': (2, 2), 'stride': (2,
2)}),
                        ('conv2d', {'kernel_size': (5, 5), 'out_channels': 32,
'padding': 2}),
                        ('conv2d', {'kernel_size': (7, 7), 'out_channels': 32,
'padding': 3}),
                        ('avg_pooling', {'kernel_size': (2, 2), 'stride': (2,
2)}),
                        ('conv2d', {'kernel_size': (5, 5), 'out_channels': 64,
'padding': 2}),
                        ('flatten', {}),
                        ('fully_connected', {}))
    }
  }
```

**> Voir les résultats des recherches d'hyperparamètres en annexe pour plus de détails sur leurs résultats**

L'architecture de ce modèle obtenu avec la dernière recherche d'hyperparamètres est la suivante :



Nous avons ensuite entraîné le modèle obtenu plus longement et changé le scheduling du learning rate pour permettre une meilleure convergence sur un plus grand nombre d'épochs en évitant l'overfitting: avec ces hyperparamètres un learning rate multiplié par  $\text{gamma}=0.3$  toutes les **40** epochs d'entraînement, on obtient: **best\_train\_loss=0.0005548** et **best\_valid\_loss=0.0004782** au bout de la 339ème epoch.

Ci dessous quelques résultats obtenus avec ce modèle sur des images du validset:




Figure 2: Inference of trained model on a random validset batch of 16 images

On peut constater sur les exemples ci-dessus que le modèle de détection de balle et de classification de leur couleur fonctionne, malgré quelques petites imprécisions sur la position exacte de la balle (underfitting léger sur les coordonnées).

**Tache 2: Modèle de prédiction de position de balles (voir `../src/balldetect/seq_prediction.py` et les hyperparamètres associés dans `../src/train.py`)**

Le modèle de prédiction de position de balles est un simple réseau de neurones dense (fully connected layers) puisque qu'il n'y a pas d'images en entrée du modèle.

Pour simplifier l'entraînement du modèle, nous avons transformé les données pour enlever la redondance d'information sur la couleur des balles. En effet, puisque la couleur des balles ne changent pas dans la séquence, nous entraînons le modèle pour ne prédire que trois bounding boxes (la position des trois balles données en entrée).

Nous enlevons donc les vecteurs nuls des bounding boxes en entrée ( $19 \times 3 \times 4$  coordonnées) et des

bounding box cibles (3 x 4 coordonnées). Nous donnons également le vecteur de couleurs (de taille 9) au cas où la couleur des balles donnerais de l'information sur les propriétés physiques des balles. Cette simplification des données permet une convergence bien plus rapide et meilleure.

Le modèle est un réseaux composé uniquement de couches denses (fully connected). Les couches sont définies de manière similaire aux couches denses du modèle de détection (tâche 1) à la différence près de la fonction d'activation utilisée : `nn.tanh` et, bien sûr, à leur largeur près.

La procédure d'entrainement du modèle est relativement similaire à celle du modèle de détection de la tâche 1, aux hyperparamètres près. Le modèle est entraîné sur le dataset `../dataset/mini_balls_seq` avec une séparation aléatoire entre validset (10% du dataset) et du trainset (90% du dataset), sans testset pour éviter de perdre trop de données, étant donné la petite taille du dataset. Nous n'avons malheureusement pas pu travailler autant que voulu sur l'interprétation de la qualité des prédictions faites sur les positions des balles au delà de la métrique utilisée, la MSE calculée sur les trois bounding boxes de sortie normalisées par le vecteur `balldetect.datasets.BBOX_SCALE`.

Ci-dessous, l'espace de recherche d'hyperparamètres utilisée pour trouver les paramètres de ce modèle:

```
{
    'optimizer_params': {'lr': hp.uniform('lr', 5e-6, 1e-4), 'betas': (0.9,
0.999), 'eps': 1e-8, 'weight_decay': hp.loguniform('weight_decay', math.log(1e-7),
math.log(1e-2)), 'amsgrad': False},
    'scheduler_params': {'step_size': EPOCHS, 'gamma': 1.},
    # 'scheduler_params': {'max_lr': 1e-2, 'pct_start': 0.3, 'anneal_strategy':
'cos'},
    'batch_size': hp.choice('batch_size', [32, 64, 128]),
    'architecture': {
        'act_fn': hp.choice('batch_size', [nn.LeakyReLU, nn.ReLU, nn.Tanh]),
        'dropout_prob': hp.choice('dropout_prob', [1.,
hp.uniform('nonzero_dropout_prob', 0.45, 0.8)]),
        # Fully connected network hyperparameters (a final FC inference layer with
no dropout nor batchnorm will be added when ball position predictor model is
instantiated)
        'fc_params': hp.choice('fc_params', [[{'out_features': 512},
{'out_features': 256}] + [{'out_features': 128}] * 2,
                                     [{'out_features': 128}] +
[{'out_features': 256}] * 2 + [{'out_features': 512}],
                                     [{'out_features': 128}] +
[{'out_features': 256}] * 3,
                                     [{'out_features': 128}] * 2 +
[{'out_features': 256}] * 3,
                                     [{'out_features': 128}] * 2 +
[{'out_features': 256}] * 4,
                                     [{'out_features': 128}] * 3 +
[{'out_features': 256}] * 4]))
    }
```

Le meilleur modèle trouvé à pour hyperparamètres le dictionnaire suivant (`best_valid_mse=0.0005018`, `best_train_mse=0.0005203`, at 78th epoch over 90 epochs):

```

SEQ_PRED_HP = {
    'batch_size': 16,
    'early_stopping': 30,
    'epochs': 400,
    'optimizer_params': {'amsgrad': False, 'betas': (0.9, 0.999), 'eps': 1e-08,
    'lr': 9.891933484569264e-05, 'weight_decay': 2.0217734556558288e-4},
    'scheduler_params': {'gamma': 0.3, 'step_size': 30},
    'architecture': {
        'act_fn': nn.Tanh,
        'dropout_prob': 0.44996724122672166,
        'fc_params': ({'out_features': 512},
                       {'out_features': 256},
                       {'out_features': 128},
                       {'out_features': 128})
    }
}

```

Une fois ce modèle entraîné sur plus d'epochs et un learning rate scheduler adapté, avec `../src/train.py`, nous obtenons les résultats suivants : **best\_valid\_mse=0.0003570** et **best\_train\_mse=0.0002038** au bout de la 270ème epoch d'entraînement (early stopping à la 300ème epoch).

Malheureusement, malgré les dispositions sur la reproductibilité, si l'on relance l'entraînement, nous obtenons les résultats suivants (peut-être lié à l'optimisation de CuDNN non-deterministe) :

**best\_train\_mse=0.0005548** et **best\_valid\_mse=0.0004782** à la 173ème epoch (early stopping à la 203ème epoch).

Je n'ai pas eu le temps de mieux interpréter les valeurs de loss pour ce modèle et pour visualiser les séquences de bounding boxes inférées.

Il aurait aussi été intéressant de voir le comportement du modèle si appliqué de manière "récurrente" en donnant pour séquence d'entrée les 18 dernières positions et la position inférée précédemment pour en déduire la position de la balle à l'instant  $t+2$  et ainsi de suite... (plus ou moins similaire à l'application d'un RNN avec une 'fenêtre contextuelle' de 20 étapes, mais sans features représentant l'état interne du RNN)

## Conclusion

Pour conclure, développer et tester des modèles Pytorch, certes simples, m'a permis d'approfondir mes connaissances en deep learning, notamment d'un point de vue pratique/technique.

Il est regrettable que l'interprétation des métriques et la visualisation des résultats de la tâche 2 souffre d'un manque de temps (ou plutôt, est la conséquence des priorités données aux différents aspects du projet). Cependant, nous avons pu développer des modèles Pytorch et des procédures d'entraînement assez fonctionnels, complets, générique et réutilisables. En effet, ce projet a également été l'occasion de poser une base de code relativement solide pour de futurs projets en Pytorch.

## Autres pistes et améliorations possibles

- travailler d'avantage sur l'interprétation et l'investigation des métriques: calculer des métriques plus interprétables que la loss de la tâche 1 qui n'est pas vraiment interprétable en l'état.



- exploiter d'avantage d'a priori sur le vecteur des couleurs lors de la detection de balles de la tâche 1 : sur les 9 valeurs binaires du vecteur de couleurs, 3 sont à 1 et les autres à 0, or, notre modèle est entraîné pour faire une classification multi-classes (vecteur de couleurs en sortie de taille 9 avec une binary cross-entropy loss) alors qu'il pourrait s'agir de classifier 3 valeurs (comprises entre 0 et 8) représentant les index des 3 valeurs à 1 dans le vecteur de couleurs. Cependant, il n'est pas certains que cette approche améliorerait les performances puisque prédire une 'simili-lookup table' (ou embedding layer) a ses avantages : empiriquement on constate souvent que la qualité des prédictions est meilleures ainsi (probablement car les gradients sont moins 'intriqués' en sortie et chaque possibilités de classification à une sortie dédiée, donc un parcours dans le réseaux plus indépendant).
- finir l'implémentation de la sauvegarde de modèles et du logging des métriques pour tensorboard (utilisation de tensorboard avec Pytorch pour mieux diagnostiquer et visualiser l'entraînement).
- exploiter l'as prioris sur les coordonnées des bounding boxes: non seulement les coordonnées sont dans un certain ordre mais, dans ce dataset, toutes les balles sont environs de la même taille, on pourrait donc simplement faire une regression sur, par exemple, la moyennes des deux coordonnées d'une bounding box (centre de la balle). De manière moins agressive, on pourrait aussi ajouter un terme dans la loss encourageant un certain ordre entre les valeurs des coordonnées des bounding boxes.
- utiliser la mean average precision combinée avec une métrique *d'Intersection over Union* (IoU) pour la regression des bounding boxes, comme utilisée sur le dataset Pascal VOC
- utiliser de la cross validation étant donné la petite taille du dataset
- créer un petit testset pour évaluer très ponctuellement le modèle autrement que par le validset qui pourrait être compromis par la recherche d'hyperparamètres
- utiliser des méthodes de recherche d'hyperparamètres plus efficaces (e.g. la méthode utilisée par fastai dans [callbacks.lr\\_finder](#): [post de blog de Sylvain Gugger](#)) et utilisation de [microsoft/nni](#) regroupant de nombreuses de méthodes de recherche d'hyperparamètres)
- utiliser des méthodes de recherche d'architecture automatiques (beaucoup d'engouement/progrès dans la communauté deeplearning autour des méthodes de "neural net architecture search" et "meta-learning")
- tests plus poussés du scheduling de learning rate (e.g. investiger pourquoi OneCycle learning rate scheduler n'a pas donné de résultats probants sur la détection de balles avec notre modèle)
- utiliser de l'augmentation de données aurait pû être intéressant
- comparer les résultats et approches avec le papier <https://arxiv.org/pdf/1909.12000.pdf>



Copyright (c) 2019 Paul-Emmanuel SOTIR

**This project and document is under open-source MIT license, browse to:**

**<https://github.com/PaulEmmanuelSotir/BallDetectionAndForecasting/blob/master/LICENSE> for full MIT license text.**

## Annexe : recherches d'hyperparamètres

---

...



# Ball detection and forecasting notebook - Hyperparameters search results notebook

Paul-Emmanuel sotir [paul-emmanuel@outlook.com](mailto:paul-emmanuel@outlook.com)

## Task 1: Detection hyperparameter search results

We ran 3 different hyperparameter searches.

The last one ([./hp\\_search\\_logs/hp\\_detect3.log](#)) trains the latest version of the model which performs better:

- First/older hyperparameter search's best trial: **best\_valid\_loss=0.0313197** (didn't performed well due to early, buggy model implementation)
- Second hyperparameter search's best trial: **best\_valid\_loss=0.0039857**
- Third/latest hyperparameter search's best trial: **best\_valid\_loss=0.0031991**


See following visualizations for better understanding of hyperparameter search results on ball detection model:


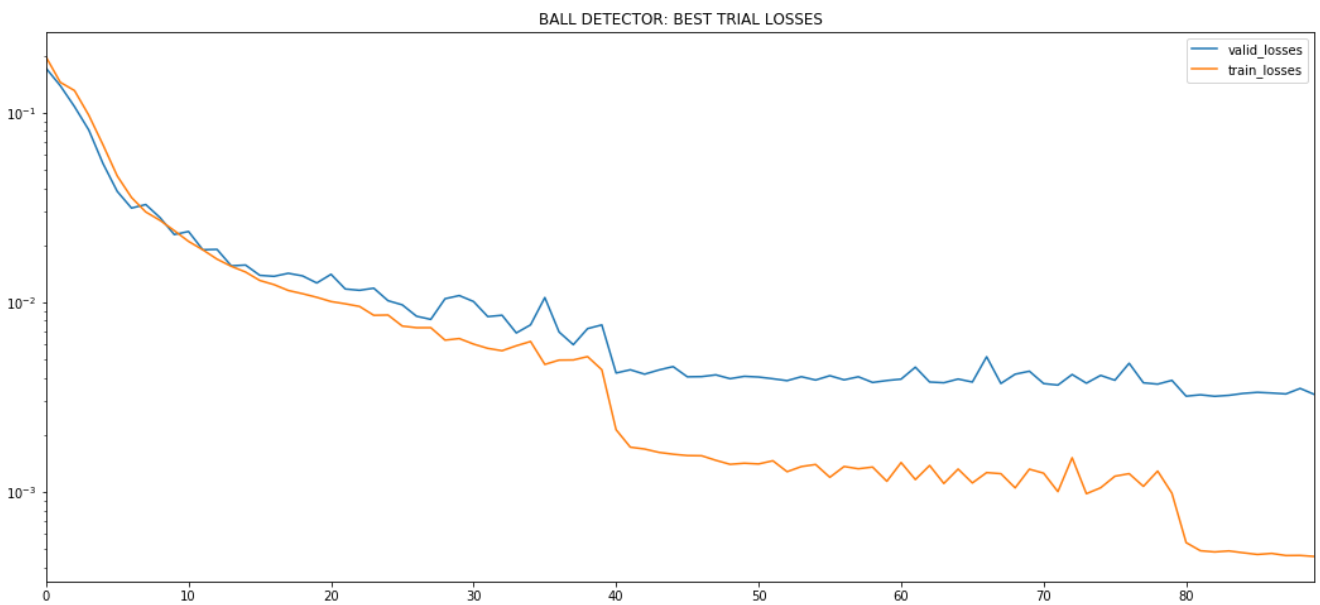
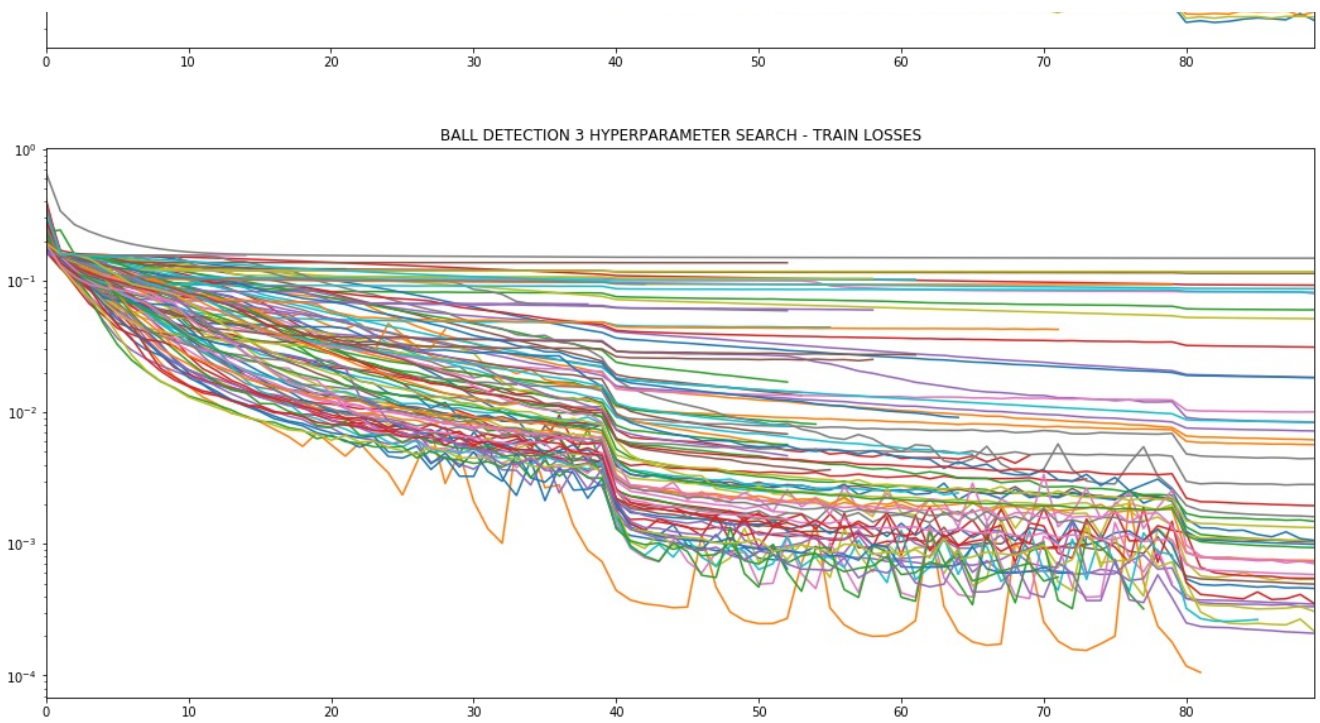
### Ball detection - Hyperparameter search 3 (latest)

In [109]:

```
summarize_hp_search(r'../hp_search_logs/hp_detect3.log', 'Ball detection 3')
```

```
WARNING: Can't parse hyperparameter search trial NO#0.
##### BALL DETECTION 3 HYPERPARAMETER SEARCH RESULTS #####
Hyperparameter search ran 100 trials. Best trial (30th trial) results:
Best_valid_loss=0.0031991 at epoch=82
Hyperparameters:
({'architecture': {'act_fn': <class 'torch.nn.modules.activation.ReLU'>, "
  "batch_norm": {'affine': True, 'eps': 1e-05, 'momentum': "
  "0.07359778246238029}, 'dropout_prob': 0.0, 'layers_param': (('conv2d', "
  "{ 'kernel_size': (3, 3), 'out_channels': 4, 'padding': 0}), ('conv2d', "
  "{ 'kernel_size': (3, 3), 'out_channels': 4, 'padding': 0}), ('conv2d', "
  "{ 'kernel_size': (3, 3), 'out_channels': 4, 'padding': 0}), ('avg_pooling', "
  "{ 'kernel_size': (2, 2), 'stride': (2, 2)}), ('conv2d', { 'kernel_size': (5, "
  "5), 'out_channels': 16, 'padding': 0}), ('conv2d', { 'kernel_size': (5, 5), "
  "'out_channels': 16, 'padding': 0}), ('avg_pooling', { 'kernel_size': (2, 2), "
  "'stride': (2, 2)}), ('conv2d', { 'kernel_size': (5, 5), 'out_channels': 32, "
  "'padding': 2}), ('conv2d', { 'kernel_size': (7, 7), 'out_channels': 32, "
  "'padding': 3}), ('avg_pooling', { 'kernel_size': (2, 2), 'stride': (2, 2)}), "
  "('conv2d', { 'kernel_size': (5, 5), 'out_channels': 64, 'padding': 2}), "
  "('flatten', {}), ('fully_connected', {}))}, 'batch_size': 16, "
  "'optimizer_params': {'amsgrad': False, 'betas': (0.9, 0.999), 'eps': 1e-08, "
  "'lr': 0.0006537177808319479, 'weight_decay': 6.841231983628692e-06}, "
  "'scheduler_params': {'gamma': 0.3, 'step_size': 40}})
```






Out[109]:

## Best valid\_loss obtained for each hyperparameter search trials

count	100.000000
mean	0.034872
std	0.038299
min	0.003199
25%	0.006701
50%	0.018672
75%	0.047386
max	0.156067



## Ball detection - Hyperparameter search 2

In [107]:

```
summarize_hp_search(r'../hp_search_logs/hp_detect2.log', 'Ball detection 2')
```

WARNING: Can't parse hyperparameter search trial NO#0.


##### BALL DETECTION 2 HYPERPARAMETER SEARCH RESULTS #####


Hyperparameter search ran 100 trials. Best trial (71th trial) results:

Best\_valid\_loss=0.0039857 at epoch=82


Hyperparameters:

```
("{'architecture': {'act_fn': <class 'torch.nn.modules.activation.ReLU'>, "
  "'batch_norm': {'affine': True, 'eps': 1e-05, 'momentum': "
  "0.10000855478007505}, 'dropout_prob': 0.0, 'layers_param': (('conv2d', "
  "{ 'kernel_size': (3, 3), 'out_channels': 4, 'padding': 0}), ('conv2d', "
  "{ 'kernel_size': (3, 3), 'out_channels': 4, 'padding': 0}), ('conv2d', "
  "{ 'kernel_size': (3, 3), 'out_channels': 4, 'padding': 0}), ('avg_pooling', "
  "{ 'kernel_size': (2, 2), 'stride': (2, 2)}), ('conv2d', { 'kernel_size': (5, "
  "5), 'out_channels': 16, 'padding': 0}), ('conv2d', { 'kernel_size': (5, 5), "
  "'out_channels': 16, 'padding': 0}), ('avg_pooling', { 'kernel_size': (2, 2), "
  "'stride': (2, 2)}), ('conv2d', { 'kernel_size': (5, 5), 'out_channels': 32, "
  "'padding': 2}), ('conv2d', { 'kernel_size': (7, 7), 'out_channels': 32, "
  "'padding': 3}), ('avg_pooling', { 'kernel_size': (2, 2), 'stride': (2, 2)}), "
  "('conv2d', { 'kernel_size': (5, 5), 'out_channels': 64, 'padding': 2}), "
  "('flatten', {}), ('fully_connected', {}))}, 'batch_size': 16, "
  "'bce_loss_scale': 0.1, 'early_stopping': 12, 'epochs': 90, "
  "'optimizer_params': {'amsgrad': False, 'betas': (0.9, 0.999), 'eps': 1e-08, "
  "'lr': 0.0005861368569651883, 'weight_decay': 7.577129485468843e-05}, "
  "'scheduler_params': {'gamma': 0.3, 'step_size': 40}}")
```







BALL DETECTION 2 HYPERPARAMETER SEARCH - TRAIN LOSSES



BALL DETECTOR: BEST TRIAL LOSSES




Best valid\_loss obtained for each hyperparameter search trials

Out [107]:

Best valid\_loss obtained for each hyperparameter search trials

count	100.000000
mean	0.044048
std	0.046648
min	0.003986
25%	0.008889
50%	0.021954
75%	0.067262
max	0.156816

Best valid\_loss obtained for each hyperparameter search trials



## Ball detection - Hyperparameter search 1 (first, early model implementation)

In [108]:

```
summarize_hp_search(r'../hp_search_logs/hp_detect1.log', 'Ball detection 1')
```

WARNING: Can't parse hyperparameter search trial NO#0.

##### BALL DETECTION 1 HYPERPARAMETER SEARCH RESULTS #####


Hyperparameter search ran 100 trials. Best trial (78th trial) results:

Best valid\_loss=0.0313197 at epoch=89


Hyperparameters:

```
("{'architecture': {'act_fn': <class 'torch.nn.modules.activation.LeakyReLU'>, "  
"conv2d_params': ({'kernel_size': (3, 3), 'out_channels': 4, 'padding': 1}, "  
"{'kernel_size': (3, 3), 'out_channels': 4, 'padding': 1}, {'kernel_size': "  
"(3, 3), 'out_channels': 8, 'padding': 1}, {'kernel_size': (3, 3), "  
"out_channels': 8, 'padding': 1, 'stride': 2}, {'kernel_size': (5, 5), "  
"out_channels': 16, 'padding': 2}), 'dropout_prob': 1.0, 'fc_params': "  
"({'out_features': 64}, {'out_features': 128})}, 'batch_size': 32, "  
"optimizer_params': {'amsgrad': False, 'betas': (0.9, 0.999), 'eps': 1e-08, "  
"lr': 9.40322636322488e-05, 'weight_decay': 3.5870764284550168e-06}, "  
"scheduler_params': {'gamma': 1.0, 'step_size': 90}}")
```


BALL DETECTION 1 HYPERPARAMETER SEARCH - VALID LOSSES









BALL DETECTION 1 HYPERPARAMETER SEARCH - TRAIN LOSSES



BALL DETECTOR: BEST TRIAL LOSSES




Best valid\_loss obtained for each hyperparameter search trials

Out [108]:

Best valid\_loss obtained for each hyperparameter search trials

count	100.000000
mean	0.104104
std	0.041804
min	0.031320
25%	0.069580
50%	0.092948
75%	0.153632
max	0.158702

Best valid\_loss obtained for each hyperparameter search trials



## Task 2: Ball position forecasting hyperparameter search results

We ran 2 different hyperparameter searches.

- The last one ([./hp\\_search\\_logs/hp\\_forecast2.log](#)) trains the latest version of the model.
- The first one runs an early version of ball position forecasting model ([./hp\\_search\\_logs/hp\\_forecast1.log](#))

Even though the first hyperparameter search did find a better model (`best_valid_mse=0.0005018`) than the latest hp search (`best_valid_mse=0.0003088`), the latest model version seems to be more promising for further improvements during a full/regular training with more than 90 epochs. Indeed, first/older hp search trials globally didn't perform better and we can suspect that its best trial is overfitting on validset much more than the best trial of the newer/latest hp search:

- According to the following visualizations, the distribution of best validation losses of each trial is better in the latest hp search than in the first one, where the best trial could be an overfitted outlier rather than a promising hyperparameter search sub-space.
- Moreover, **train\_loss** and **valid\_loss** curve plots of first/older hp search's best trial display an important offset between **train\_loss** and **valid\_loss**: **valid\_loss** is significantly below **train\_loss** (note that plots use logarithmic scale for y axis, which means this offset is even larger than it looks like on plots). This offset doesn't necessarily mean there is important underfitting on trainset, but rather means that there is very probable overfitting on validset due to hyperparameter search.
- Another reason of this difference is related to the fact that we used multiple steps of learning rate schedule in the latest hp search while we used a lower, constant learning rate during the first hyperparameter search.

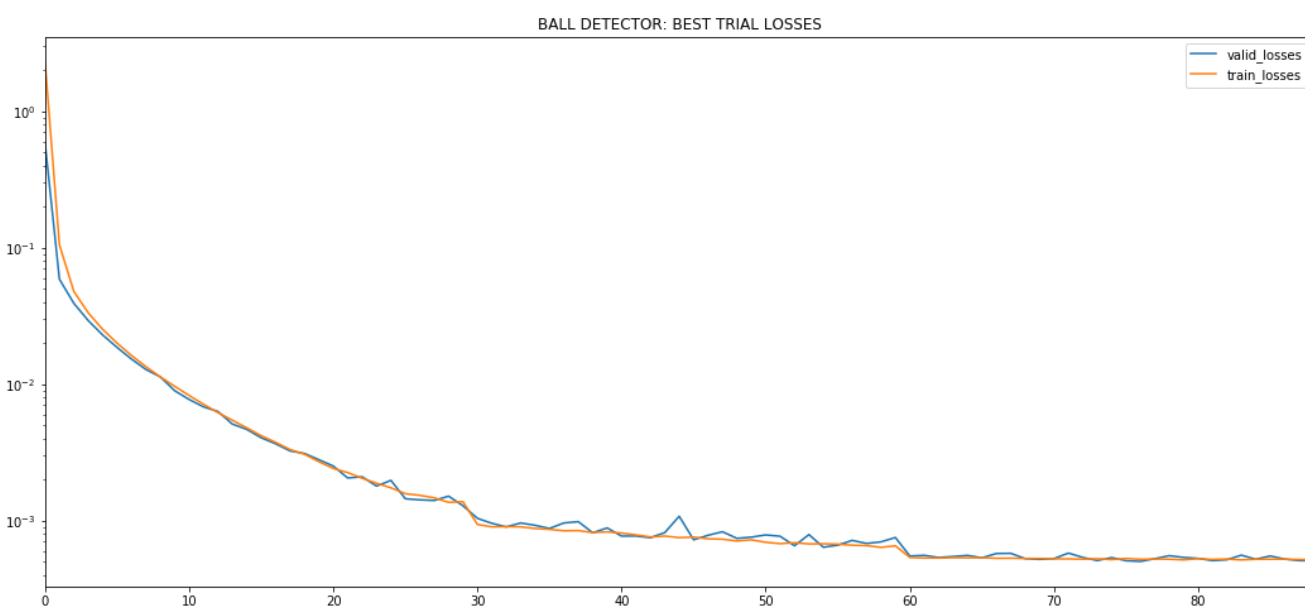
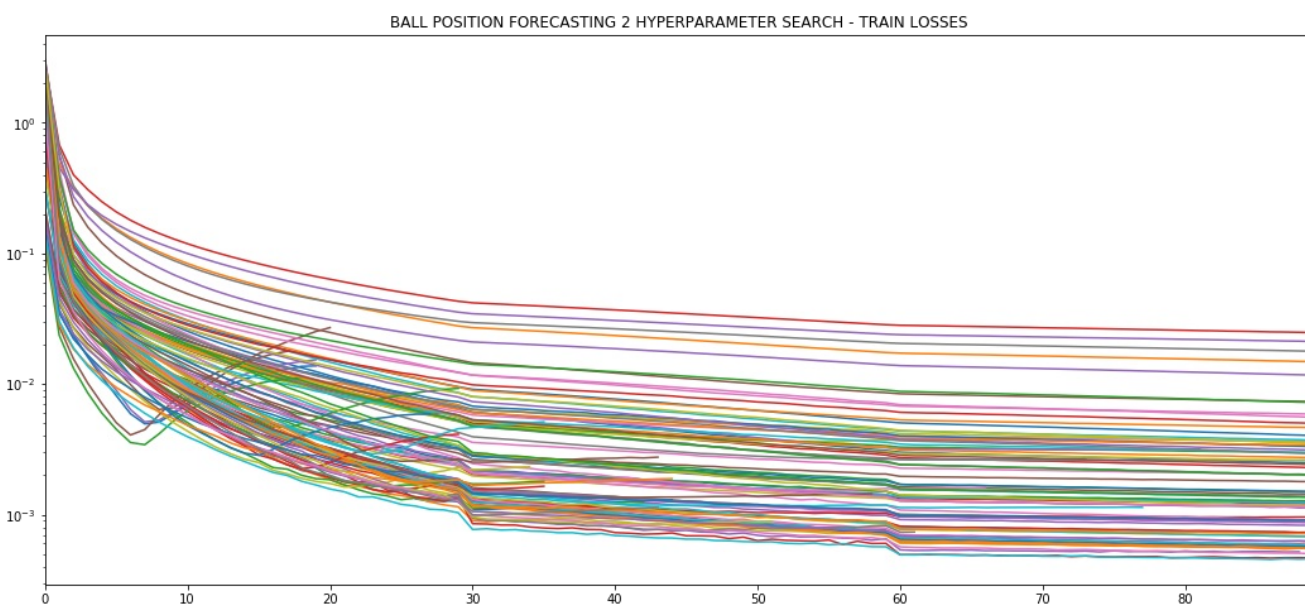

### Ball position forecasting - Hyperparameter search 2 (latest)

In [103]:


```
summarize_hp_search(r'../hp_search_logs/hp_forecast2.log', 'Ball position forecasting 2')
```

```
WARNING: Can't parse hyperparameter search trial NO#0.
##### BALL POSITION FORECASTING 2 HYPERPARAMETER SEARCH RESULTS #####
Hyperparameter search ran 100 trials. Best trial (74th trial) results:
Best_valid_loss=0.0005018 at epoch=76
Hyperparameters:
({'architecture': {'act_fn': <class 'torch.nn.modules.activation.Tanh'>, "
'dropout_prob': 0.44996724122672166, 'fc_params': ({'out_features': 512}, "
{'out_features': 256}, {'out_features': 128}, {'out_features': 128})}, "
'batch_size': 16, 'optimizer_params': {'amsgrad': False, 'betas': (0.9, "
"0.999), 'eps': 1e-08, 'lr': 9.891933484569264e-05, 'weight_decay': "
```

```
"0.00020217734556558288}, 'scheduler_params': {'gamma': 0.3, 'step_size': "
'30}}')
```








Best valid\_loss obtained for each hyperparameter search trials

Out[103]:

Best valid\_loss obtained for each hyperparameter search trials

count	100.000000
mean	0.003077
std	0.004137
min	0.000502
25%	0.001045
50%	0.001618
75%	0.003594
max	0.025560



## Ball position forecasting - Hyperparameter search 1 (first)

In [104]:

```
summarize_hp_search(r'../hp_search_logs/hp_forecast1.log', 'Ball position forecasting 1')
```

WARNING: Can't parse hyperparameter search trial NO#0.

##### BALL POSITION FORECASTING 1 HYPERPARAMETER SEARCH RESULTS #####


Hyperparameter search ran 100 trials. Best trial (72th trial) results:

Best\_valid\_loss=0.0003088 at epoch=69


Hyperparameters:

```
("{'architecture': {'act_fn': <class 'torch.nn.modules.activation.Tanh'>, "
"'dropout_prob': 1.0, 'fc_params': ({'out_features': 512}, {'out_features': "
"'256'}, {'out_features': 128}), {'batch_size': 32, "
"'optimizer_params': {'amsgrad': False, 'betas': (0.9, 0.999), 'eps': 1e-08, "
"'lr': 9.065637320023906e-05, 'weight_decay': 2.636242890889078e-06}, "
"'scheduler_params': {'gamma': 1.0, 'step_size': 90}})")
```








BALL POSITION FORECASTING 1 HYPERPARAMETER SEARCH - TRAIN LOSSES



BALL DETECTOR: BEST TRIAL LOSSES





Best valid\_loss obtained for each hyperparameter search trials

Out[104]:

Best valid\_loss obtained for each hyperparameter search trials

count	100.000000
mean	0.004782
std	0.017039
min	0.000309
25%	0.000479
50%	0.000614
75%	0.001150
max	0.089641

